DATA SCIENCE MINI PROJECT / 2026.10.01

ESS 배터리 수명 데이터 분석 및 모델 설계 전략

DAY 1

Batch 1·2·3 탐색적 데이터 분석

초기 100사이클의 변화로
총 Cycle Life를 예측하는 회귀 설계

> 핵심 신호는 초기 용량의 크기보다
> **전압별 용량 곡선의 변화**에 있었다.

김영준

울산캠퍼스 · 교육생 번호 U045

개인 실습 · 단독 수행

핵심 요약

EXECUTIVE SUMMARY

세 배치의 수명 분포와 초기 열화 신호를 비교하고, **회귀 기반 총 수명 예측**을 위한 피처·후보 모델·검증 전략을 수립했다. 분석 단위는 각 MAT 파일의 셀 기록이며, 배치 간 동일 물리 셀 연결은 아직 대조하지 않았다.

139
MAT 셀 기록

129
수명 유효 셀

100
초기 관측 사이클

표 1. EDA의 핵심 발견과 설계 연결

확인한 결과	모델 설계에 주는 의미
Batch 2의 단수명 비율은 71.8%, Batch 3의 장수명 비율은 52.3%다.	배치별 타깃 분포가 달라 Batch 1 내부 성능만으로 배치 일반화를 판단할 수 없다.
ΔQ 로그 분산과 수명의 Spearman 상관은 -0.871 / -0.709 / -0.797이다.	Batch 1에서 가장 강한 후보 신호로 단일 피처 기준 모델을 구성한다.
ΔQ 평균·최솟값의 상관은 0.993이고 VIF가 각각 117.71·154.64다.	중복 피처를 정리하고 Ridge·Elastic Net을 비교한다.
충전 시간의 상관은 Batch 1에서 양수, Batch 2에서 음수다.	충전 조건과 수명의 관계를 고정된 인과 규칙으로 사용하지 않는다.
여러 셀에서 후기 용량 감소가 가속된다.	후기 knee는 사후 진단에만 사용하고 초기 예측 입력에서 제외한다.

> **선택 태스크:** 초기 100사이클의 셀별 피처로 제공된 총 cycle_life 를 예측한다. 단일 ΔQ 로그 분산 선형 모델을 기준으로 Ridge와 Elastic Net을 비교한다. 최종 피처·모델·성능은 DAY2 내부 검증에서 결정한다.

이 보고서는 DAY1의 탐색 결과와 모델 설계 전략을 정리했다. 모델 학습과 성능 평가는 DAY2에 진행한다. 정확한 knee 검출, 타깃의 EOL 정의 대조, 배치 간 동일 물리 셀 연결 확인은 미완료다.

목차

본문의 제목을 누르면 해당 페이지로 이동한다. 쪽수는 표지를 포함한 PDF 실제 페이지 기준이다.

1. 분석 목적과 데이터 4

2. 수명 분포의 배치 차이 5

3. 방전 용량 열화 곡선 7

4. ΔQ(V)의 초기 차이 9

5. 충전 프로토콜별 평균 수명 11

6. 어떤 초기 신호가 유용한가? 15

7. 배치 비교와 회귀 태스크 18

7.2 EDA에서 모델 설계로 20

8. 후보 모델과 검증 계획 21

부록 A1. 프로토콜 원본 요약 22

부록 A2. 프로토콜 원본 요약 23

부록 A3. 프로토콜 원본 요약 24

> **읽는 순서**
> 핵심 요약에서 전체 방향을 확인한 뒤, 5개 질문의 실제 결과와 한계를 읽고 7.2절의 설계 연결 표로 이어진다.

1. 분석 목적과 데이터

ESS 운영에서는 배터리 수명에 따라 점검·교체·셀 선별 계획이 달라진다. 본 분석은 초기 사이클에 관측 가능한 신호로 총 수명을 예측할 가능성을 탐색한다. 실험용 셀 데이터의 결과를 실제 BESS의 운영 성능으로 바로 해석하지 않는다.

표 2. 원본과 분석 표본

Batch / 파일 날짜	원본	수명 유효	결측	DAY2 역할
Batch 1 / 2017-05-12	46	46	0	학습·내부 검증
Batch 2 / 2018-02-20	47	39	8	필수 최종 평가
Batch 3 / 2018-04-12	46	44	2	추가 성능 평가 생략
합계	139	129	10	DAY1은 세 배치 모두 분석

실제로 적용한 정제

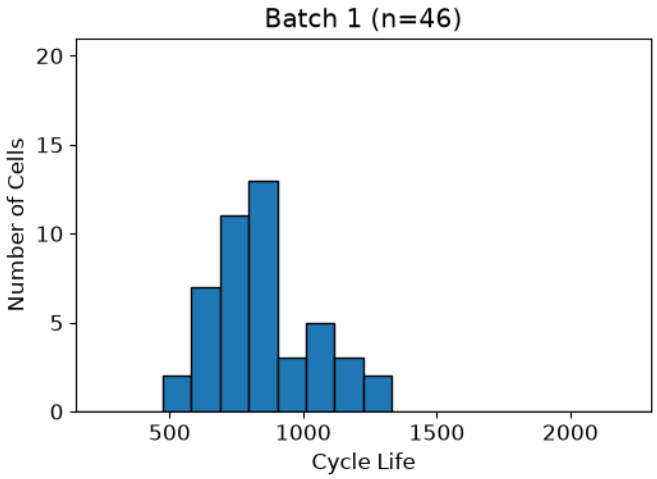
- Batch 1 summary의 첫 사이클에서 7개 주요 측정값이 모두 0인 46행을 제외했다. 38,811행에서 38,765행으로 줄었고 46셀은 유지됐다.
- 곡선 분석은 원래 사이클 번호를 보존하고 초기 빈 기록 및 비유한 cycle/Qd를 마스킹했다. Batch 2·3의 제외 기록 수는 추가 확인이 필요하다.
- 수명 결측은 대체하지 않았다. 수명과 관련된 통계는 유효 129셀, ΔQ 계산은 139셀을 사용했다.

> 수명 요약은 **셀별 한 행**으로 계산했다. Batch 1의 평균 수명은 **844.7사이클**이다.

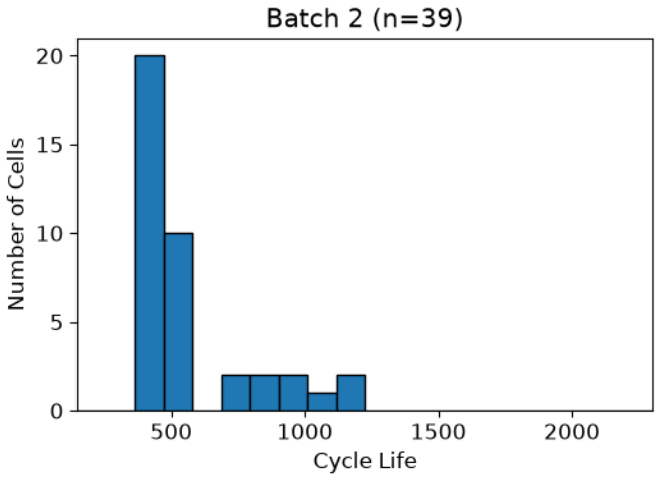
2. 수명 분포의 배치 차이

EDA QUESTION 01

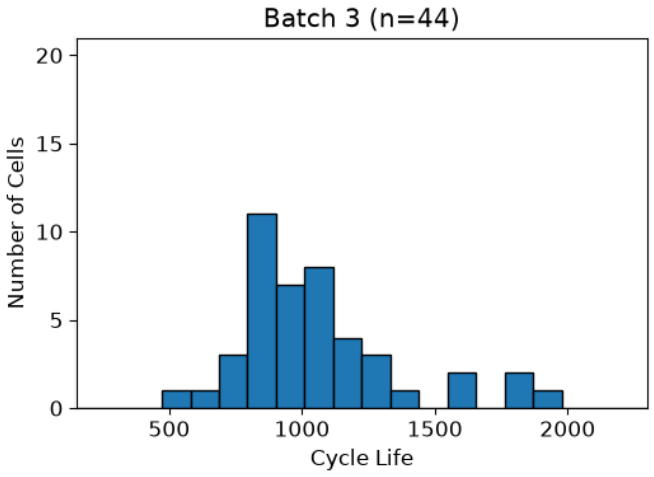
수명이 관측된 셀에 동일한 150–2,300사이클 범위와 20개 bin을 적용했다. 세 패널의 x·y축 범위는 동일하다.



Batch 1
유효 46셀. 주로 중간 수명 구간에 분포하며 단수명(<500) 셀은 없다. 중앙값은 858.5사이클이다.



Batch 2
유효 39셀. 400–500사이클 부근에 많은 셀이 집중돼 있다. 중앙값은 472.0사이클이다.



Batch 3
유효 44셀. 긴 수명 방향의 꼬리가 나타난다. 중앙값은 1,005.5사이클이다.

그림 1. 셀별 Cycle Life 분포. x축: 사이클, y축: 셀 수. 유효 표본 46/39/44; 결측 0/8/2. 표시 범위 밖 유효 셀은 0개다.

2.1 수명 비율과 짧은 셀

표 3. 유효 수명의 셀별 요약통계 (사이클)

배치	최솟값	중앙값	평균	최댓값
Batch 1	534.0	858.5	844.7	1227.0
Batch 2	392.0	472.0	565.7	1186.0
Batch 3	541.0	1005.5	1059.7	1935.0

표 4. 장·중·단수명 비율; 경계 500·1,000은 중간 그룹

배치 / 분모	단수명 <500	중간 500–1,000	장수명 >1,000
Batch 1 / 46	0 (0.0%)	36 (78.3%)	10 (21.7%)
Batch 2 / 39	28 (71.8%)	8 (20.5%)	3 (7.7%)
Batch 3 / 44	0 (0.0%)	21 (47.7%)	23 (52.3%)

중간 그룹 수와 비율은 유효·장·단수명 수에서 산술적으로 도출했다. Batch 1·3의 단수명 그룹 없음은 그대로 유지했다.

짧은 수명과 이상치의 구분

식별된 단수명 셀 28개는 모두 Batch 2다. 가장 짧은 셀은 **(Batch 2, cell_id 19), 392사이클**이며, 다음은 cell_id 6의 393, cell_id 15의 396사이클이다. Batch 2의 다수를 차지하므로 단수명 셀을 곧바로 통계적 이상치나 데이터 오류로 판단하지 않는다.

표 5. 수명이 짧은 상위 셀; cell_id는 원본 0-based 인덱스

Batch 2의 짧은 셀	수명	판단
19 / 6 / 15	392 / 393 / 396	현재 자료의 최단수명 후보
21 / 30	408 / 412	모두 단수명 기준에 해당

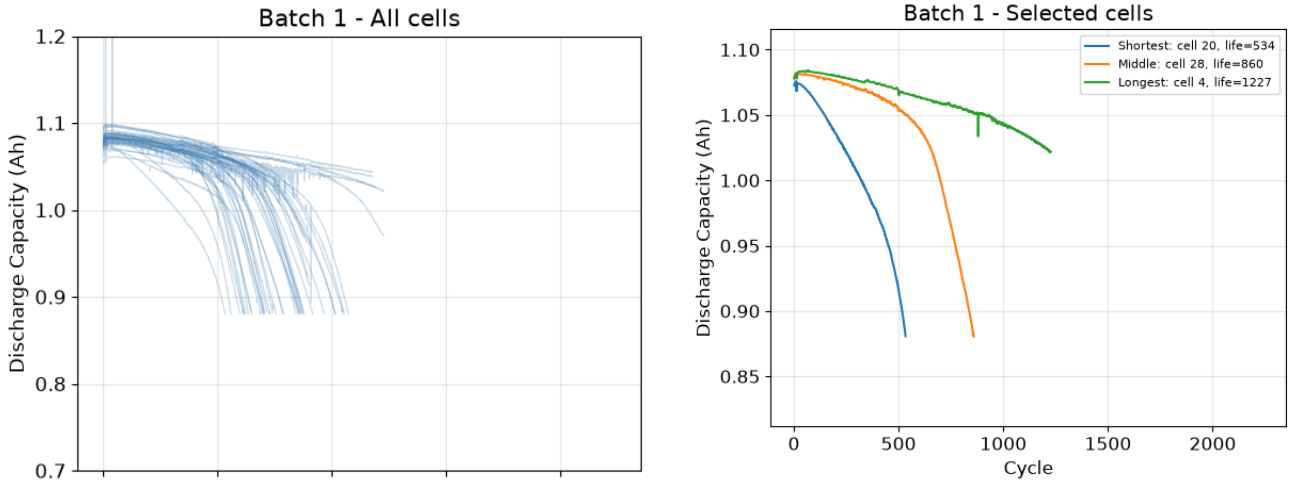
> **설계 시사점:** Batch 1에는 500사이클 미만 셀이 없지만 Batch 2에는 많다. 짧은 수명 영역은 학습에서 충분히 관측되지 않아 평가 시 일반화가 어려울 수 있다. 이 차이를 test 셀 삭제나 test 기반 튜닝으로 보정하지 않는다.

짧은 수명의 원인은 현재 확정되지 않았다. 이후 확인한 충전 프로토콜·초기 신호 차이는 가능한 설명 후보이며, 고장 원인이나 특정 열화 기전을 증명하지 않는다.

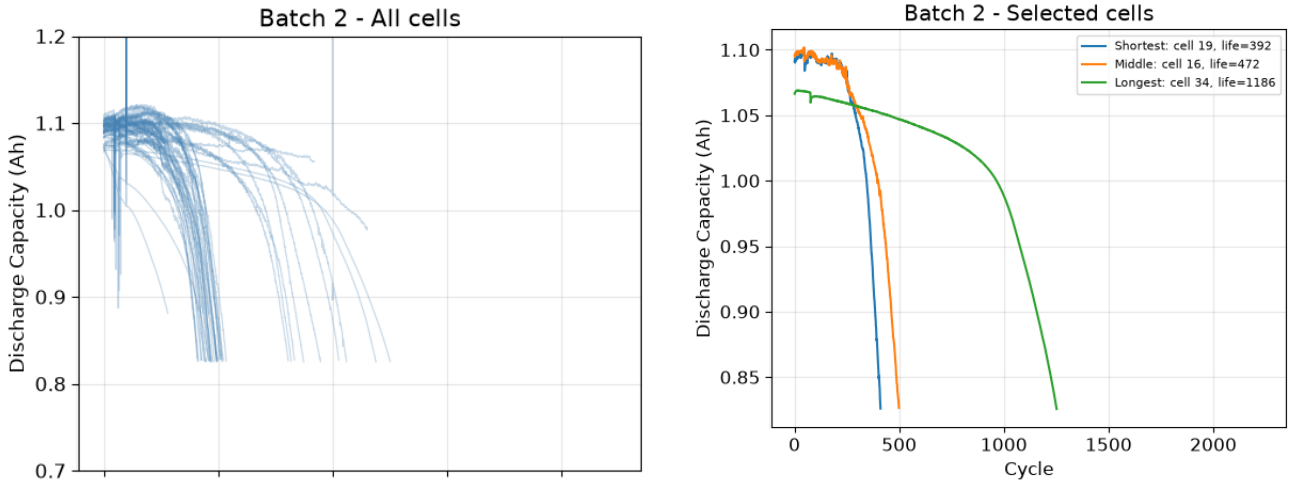
3. 방전 용량 열화 곡선

실제 사이클 번호에 따라 방전 용량(Ah)을 표시했다. 왼쪽 전체 곡선은 수명 결측 셀도 포함한다. 오른쪽은 유효 수명 순서의 최단·중간 순위·최장 셀이다.

Batch 1 · 빈 초기 기록 제외·표시 범위만 조정



Batch 2 · 이른 급격한 감소가 다수



Batch 3 · 더 오래 유지되는 곡선 포함

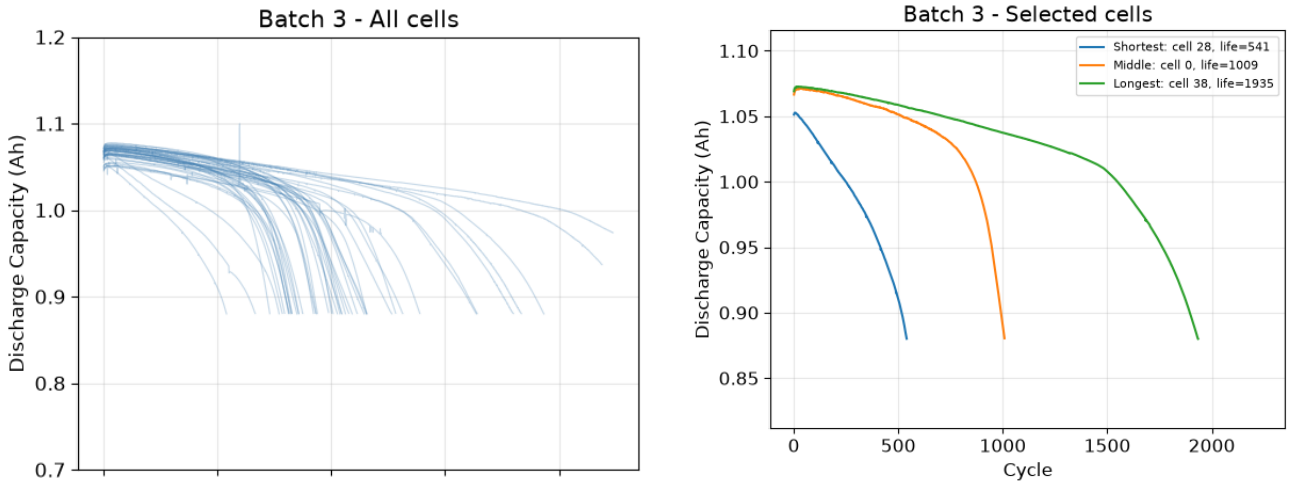


그림 2. 왼쪽: 전체 셀의 Qd 추이. 오른쪽: 대표 셀의 Qd 추이. 전체 46/47/46셀, 대표 각 3셀. 좌·우 x축은 동일한 Cycle 범위; 전체 y축: 0.7–1.2 Ah, 대표 y축은 별도 공통 범위.

3.1 열화 가속과 knee 탐색

표 6. 대표 셀 선택 (cell_id / 제공된 수명, 사이클)

배치	최단수명 셀	중간 순위 셀	최장수명 셀
Batch 1	20 / 534	28 / 860	4 / 1,227
Batch 2	19 / 392	16 / 472	34 / 1,186
Batch 3	28 / 541	0 / 1,009	38 / 1,935

관찰한 변화

Batch 1은 셀마다 감소 시점이 다르며 일부 곡선에서 후기 감소가 가속된다. Batch 2는 여러 셀에서 더 이른 사이클에 급격한 감소가 나타난다. Batch 3에는 용량을 오래 유지하는 셀이 많지만 이후 기울기가 급해지는 곡선도 보인다.

따라서 열화 속도를 전체 수명에 걸쳐 일정하다고 가정하기 어렵다. 다만 대표 셀은 수명 순위로 선택했으므로 전체 셀의 평균 열화 형태를 뜻하지 않는다.

knee의 확인 범위

완만한 감소에서 더 급격한 감소로 전환되는 구간을 **시각적 knee 후보**로 탐색했다. 수치 임계값이나 자동 검출 알고리즘은 적용하지 않았고, 정확한 발생 사이클과 검출 성공률도 산출하지 않았다.

> **뚜렷한 후보가 보이지 않은 사례:** Batch 1의 최장수명 대표 셀(cell_id 4)은 관측 끝에서 Qd가 약 1.02 Ah로 남고 뚜렷한 knee가 보이지 않는다. 제공된 cycle_life와 EOL 도달 여부의 관계를 DAY2 전 확인해야 한다. 이를 knee가 존재하지 않는 셀 또는 완전한 EOL 관측으로 단정하지 않는다.

정제와 입력 범위

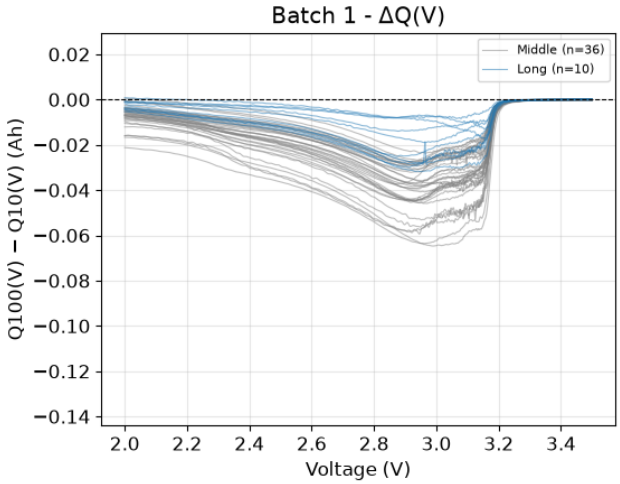
전체 그래프의 0.7–1.2 Ah 제한은 표시 범위만 바꾼 것이다. 범위를 벗어난 용량 값을 삭제하거나 후기 열화를 제거하지 않았다. 큰 용량 값이 튀는 원인은 미확인이다.

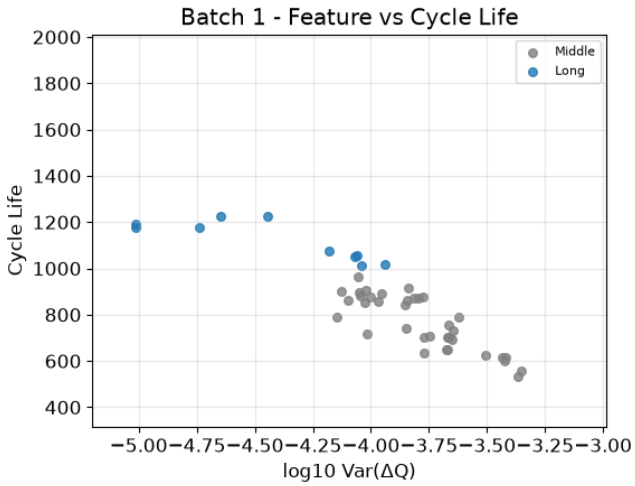
> **설계 시사점:** 초기 100사이클 안의 변화는 후보 피처로 사용하지만, 전체 생애 길이·후기 knee·종료 용량은 미래 정보이므로 초기 예측 입력에서 제외한다.

4. ΔQ(V)의 초기 차이

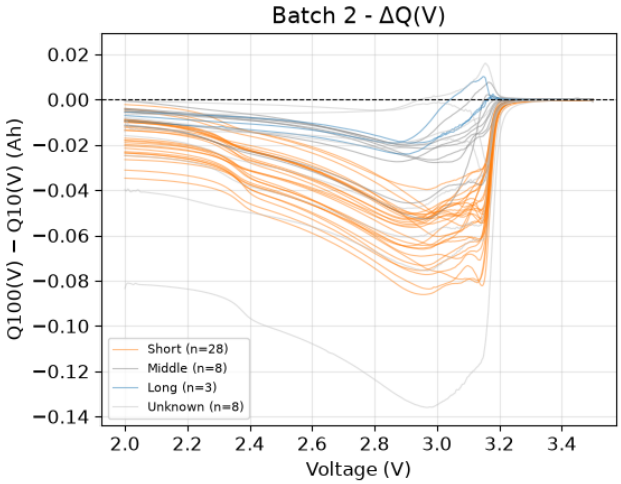
ΔQ(V)=Q100(V)−Q10(V). Short<500, Middle=500–1,000, Long>1,000이며 수명 결측은 Unknown으로 표시했다.

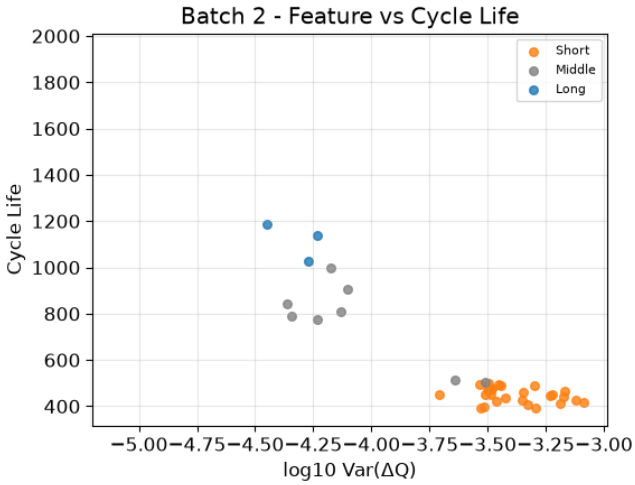
Batch 1 · Short 없음; Middle 36 / Long 10



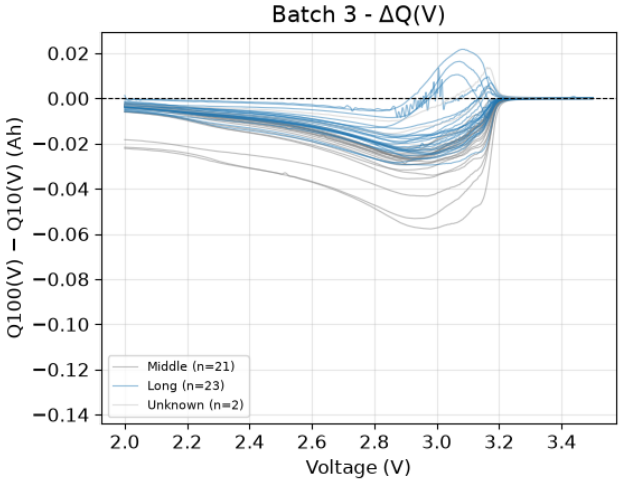


Batch 2 · Short 28 / Middle 8 / Long 3 / Unknown 8





Batch 3 · Short 없음; Middle 21 / Long 23 / Unknown 2



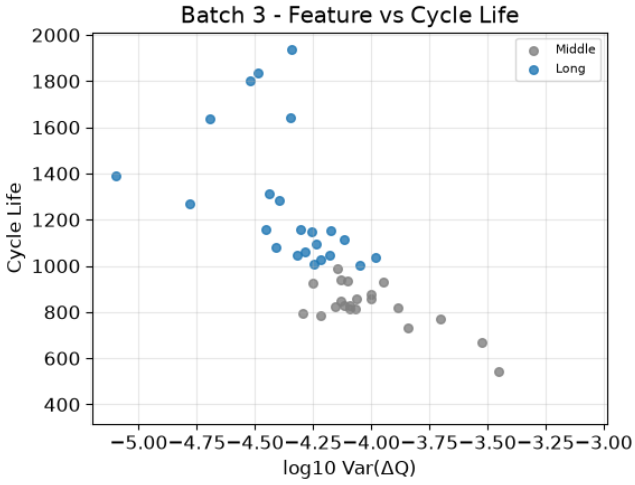


그림 3. 왼쪽: ΔQ(V) 곡선. 오른쪽: 로그 분산과 총 수명의 관계. ΔQ는 Ah, 전압은 V. 곡선은 139셀; 수명 산점도는 46/39/44셀.

4.1 ΔQ의 정의와 후보 피처

summary의 실제 cycle 번호로 10·100번째 위치를 찾고 Qdlin 참조 수와 일치하는지 확인했다. 셀별 원본 `Vdlin` 축에 맞춰 두 곡선을 함께 전압 오름차순으로 정렬했다. 이 분석에서는 새로운 보간을 실행하지 않았다.

길이·유한값·전압 중복을 확인한 뒤 ΔQ를 계산했다. **제외된 셀은 0개**다. 데이터 사전은 공통 전압축을 안내하지만, 모든 셀 간 전압축의 완전한 동일성은 별도로 검증하지 않았다.

표 7. 실제 추출한 ΔQ 통계

통계 피처	계산 정의	의미
평균 / 최솟값	전압별 ΔQ의 산술평균 / 최솟값 (Ah)	전반적 이동과 가장 큰 음의 차이
분산	전압점 전체의 Var(ΔQ), ddof=0 (Ah^2)	전압에 따라 변화량이 달라지는 정도
로그 분산	분산>0이면 log10(분산), 0이면 NaN	분산 크기를 로그 척도로 표현

표 8. 그룹별 피처 중앙값 (앞의 두 통계 단위: Ah)

배치	그룹 / n	평균 중앙값	최솟값 중앙값	로그 분산 중앙값
Batch 1	Long / 10	-0.0093	-0.0221	-4.311
Batch 1	Middle / 36	-0.0172	-0.0383	-3.786
Batch 2	Long / 3	-0.0081	-0.0192	-4.272
Batch 2	Middle / 8	-0.0112	-0.0271	-4.153
Batch 2	Short / 28	-0.0287	-0.0562	-3.446
Batch 2	Unknown / 8	-0.0193	-0.0422	-3.907
Batch 3	Long / 23	-0.0087	-0.0201	-4.317
Batch 3	Middle / 21	-0.0118	-0.0276	-4.092
Batch 3	Unknown / 2	-0.0050	-0.0129	-4.609

Batch 2 단수명 그룹의 ΔQ 최솟값 중앙값은 -0.0562 Ah로 장수명 그룹(-0.0192 Ah)보다 더 음수다. 로그 분산이 작을수록 수명이 긴 경향이 세 배치에서 관찰되지만 그룹 간 겹침이 남아 있다.

> **설계 시사점과 한계:** ΔQ 로그 분산을 핵심 후보로 검토한다. 100사이클까지 관측 가능한 셀을 대상으로 하므로 100사이클 이전 조기 고장·중단 셀에 대한 선택 편향 가능성은 남는다. 139셀 계산 성공은 이 편향이 없다는 증명이 아니다.

5. 충전 프로토콜별 평균 수명

프로토콜의 1·2단계 C-rate와 전환 SOC를 추출하고, 배치 안에서 평균 수명과 유효 표본 수를 비교했다. 평균만으로 차이의 통계적 유의성을 판단하지 않는다.

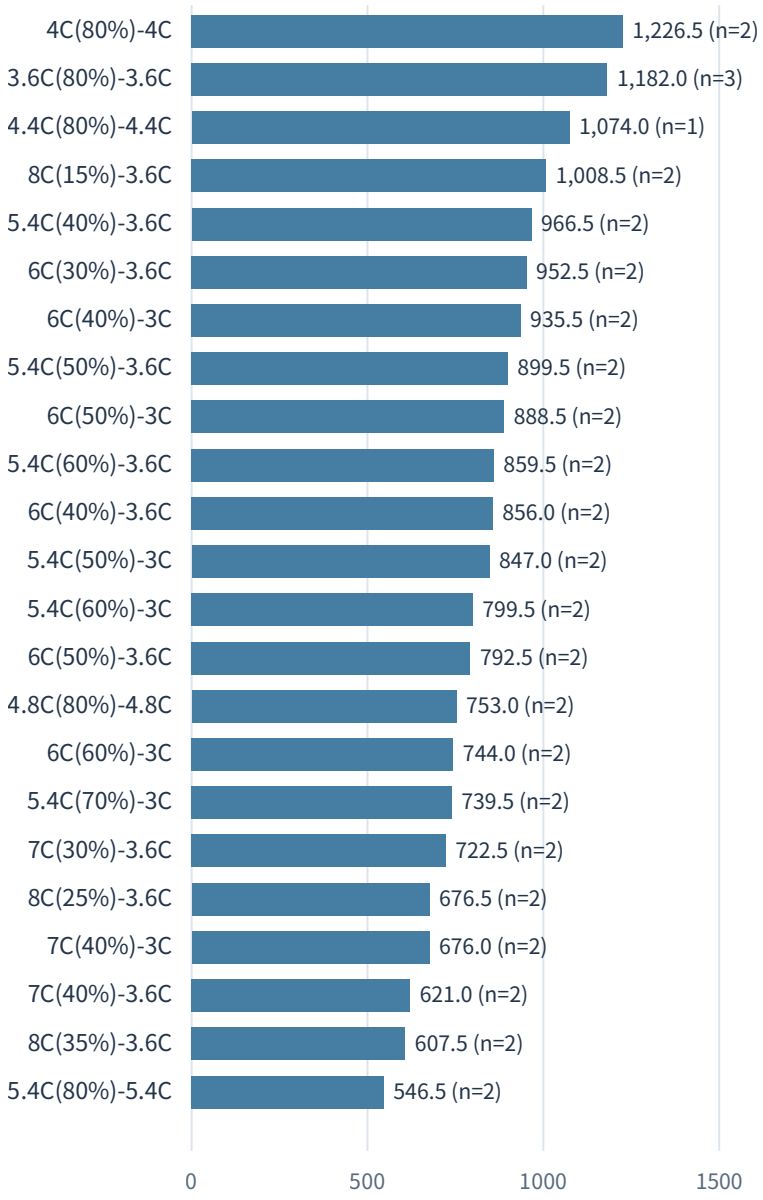


그림 4. Batch 1 프로토콜별 평균 수명(사이클)과 유효 n. 각 프로토콜 n=1–3으로 작다.

> 같은 초기 8C라도 전환 SOC 15%의 평균 수명은 1,008.5사이클, 35%는 607.5사이클이다(n=2씩). 초기 C-rate 한 개로 충전 패턴과 수명을 설명하기 어렵다.

현재 요약표에는 프로토콜별 표준편차·신뢰구간이 없으므로 오차막대를 추가하지 않았다. 전체 원본 요약은 부록에 제시했다.

5.1 Batch 2·3의 프로토콜 차이

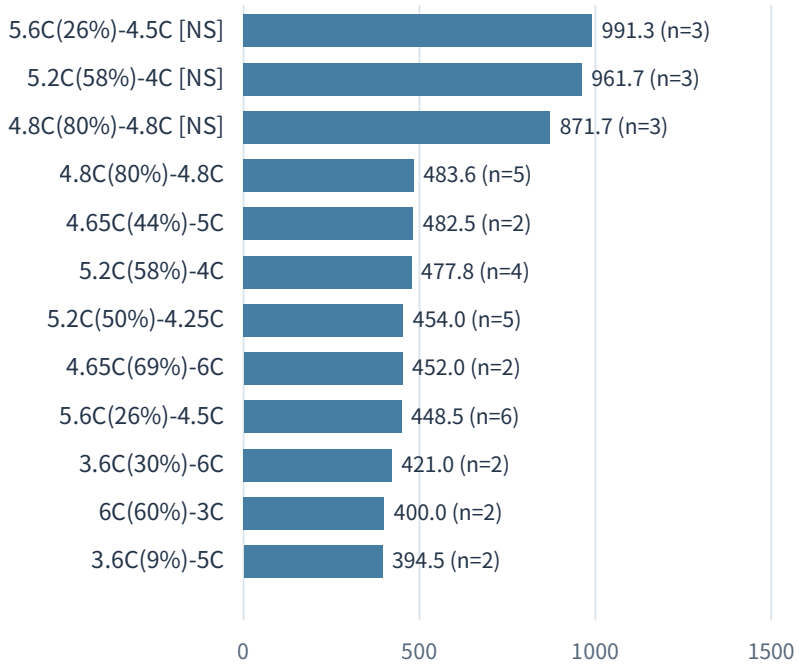


그림 5. Batch 2의 수명 유효 프로토콜. [NS]는 원본 접미사 -newstructure이며 평균 뒤 n은 수명 유효 셀 수다. 단위: 사이클.

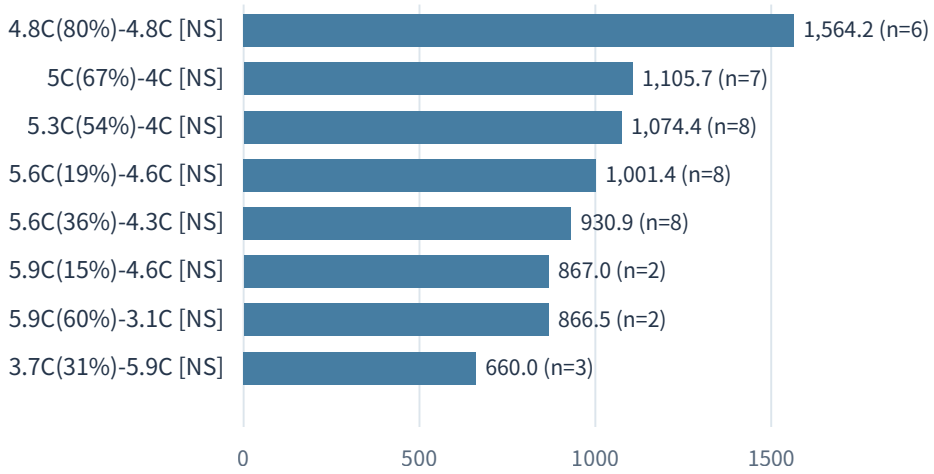


그림 6. Batch 3의 프로토콜별 평균 수명. 4.8C(80%)-4.8C [NS]는 전체 8셀 중 수명 유효 6셀이다. 단위: 사이클.

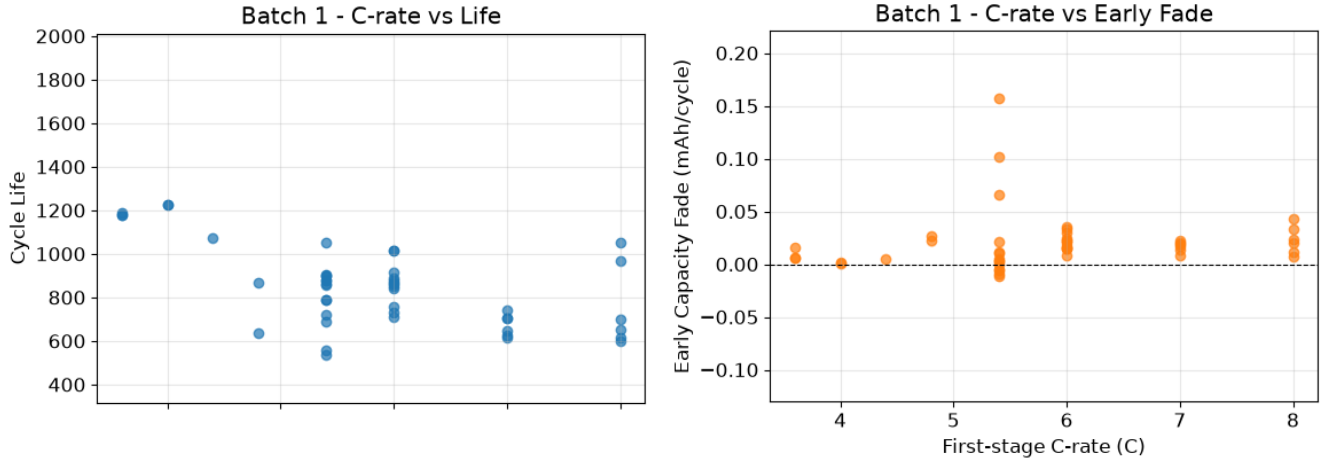
Batch 2의 `5.6C(26%)-4.5C` 평균은 448.5사이클(n=6), 같은 수치에 `-newstructure`가 붙은 그룹은 991.3사이클(n=3)이다. 추가 표기의 실제 실험 조건은 아직 확인하지 않았다.

Batch 3에서는 `4.8C(80%)-4.8C-newstructure`의 평균이 1,564.2사이클(n=6)로 높았다. 그러나 소표본·배치 구성·다른 충전 조건이 함께 달라 최적 C-rate나 인과 효과로 일반화하지 않는다.

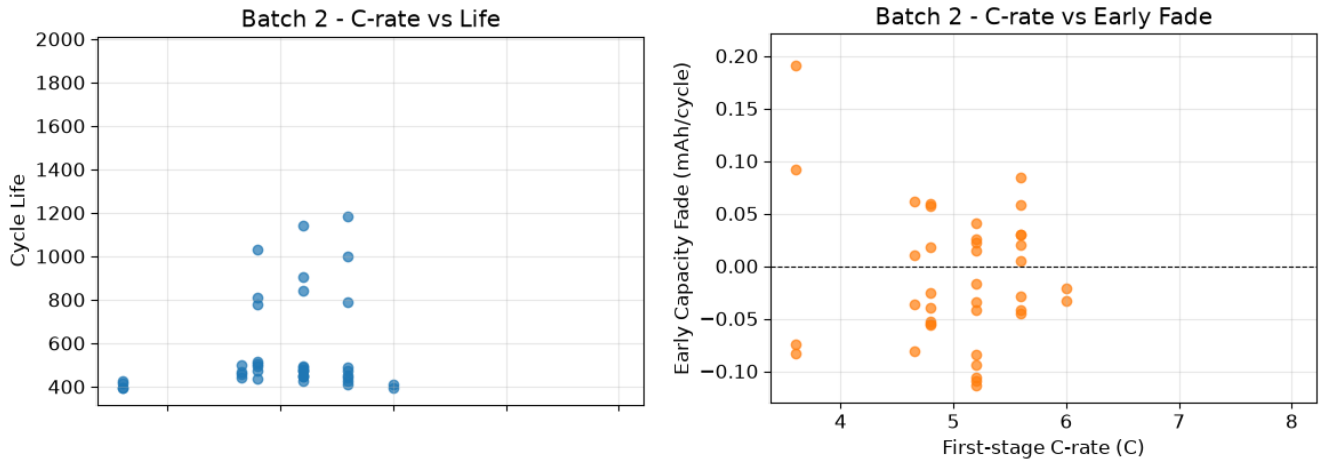
5.2 C-rate와 초기 감소율

초기 감소율은 10–100사이클 Qd의 Theil–Sen 기울기에 -1000을 곱했다. 단위는 mAh/cycle이며 양수가 클수록 용량 감소가 빠르다.

Batch 1 · 높은 C1과 짧은 수명 경향



Batch 2 · 같은 C1에서도 수명과 초기 기울기 다양



Batch 3 · 낮은 C1 일부 셀에서도 빠른 초기 감소

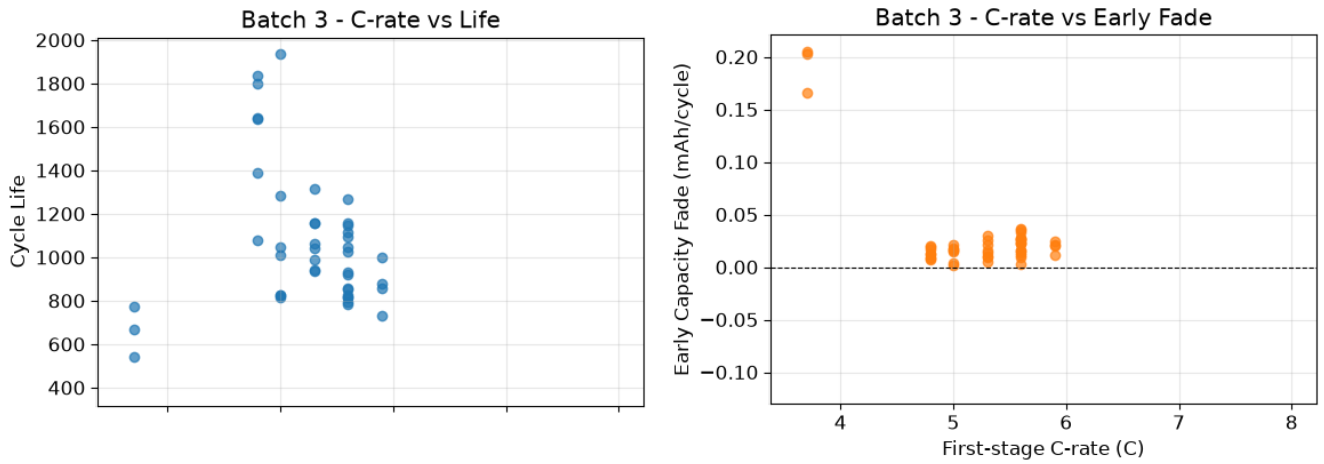


그림 7. 왼쪽: 1단계 C-rate와 수명. 오른쪽: 1단계 C-rate와 초기 용량 감소율. 왼쪽 유효 n=46/39/44; 오른쪽 n=46/39/46. 좌·우의 x축은 동일한 1단계 C-rate(C).

5.3 고속 충전의 관계와 한계

표 9. 충전 설정의 Spearman 상관

배치	설정	수명 ρ	n	감소율 ρ	n
Batch 1	1단계 C-rate	-0.483	46	0.372	46
Batch 1	2단계 C-rate	0.047	46	0.110	46
Batch 1	전환 SOC	0.185	46	-0.089	46
Batch 2	1단계 C-rate	0.055	39	0.046	39
Batch 2	2단계 C-rate	-0.119	39	0.173	39
Batch 2	전환 SOC	0.288	39	0.000	39
Batch 3	1단계 C-rate	-0.229	44	0.130	46
Batch 3	2단계 C-rate	0.016	44	0.173	46
Batch 3	전환 SOC	0.443	44	-0.427	46

Batch 1에서는 높은 1단계 C-rate가 짧은 수명(ρ=-0.483), 큰 초기 감소율(ρ=0.372)과 연결됐다. 수명 관계는 Batch 2에서 거의 없고(0.055), Batch 3에서는 약했다(-0.229).

Batch 3의 전환 SOC는 수명과 양의 관계(0.443), 초기 감소율과 음의 관계(-0.427)를 보였다. 서로 연관된 충전 설정과 통제되지 않은 조건이 있으므로 개별 변수의 효과로 단정하지 않는다.

실제 처리 범위

- 프로토콜 설정의 문자열을 분석했으며, 실제 측정 전류 I(t) 파형을 분석하지 않았다.
- Batch 2의 VarCharge 4개와 SLOWCYCLE 4개는 현재 두 단계 파싱 규칙에 맞지 않아 설정 추출에 실패했다. 설정 상관에서는 이 8셀을 제외했다.
- 초기 감소율 계산 불가 셀은 0개다. 수명이 결측이어도 감소율은 계산될 수 있다. Batch 3의 감소율 상관 n=46이 수명 상관 n=44보다 큰 이유다.
- 음수 감소율은 초기 구간의 용량 증가를 뜻한다. 이를 0으로 바꾸거나 전체 수명에서 열화가 없다고 해석하지 않았다.

> **설계 시사점:** C1·C2·전환 SOC는 충전 패턴 후보 피처로 보존하되, 추가했을 때의 이득은 Batch 1 내부 검증으로 판단한다. 입력 파싱 실패는 데이터 오류와 구분하며 특수 프로토콜의 의미를 DAY2에서 확인한다.

6. 어떤 초기 신호가 유용한가?

총 13개 후보 피처를 셀별로 만들고 수명과 Pearson·Spearman 상관을 계산했다. Pearson은 선형 관계, Spearman은 순위 관계를 비교한다. 표의 순서는 Batch 1의 |Spearman ρ| 기준이다.

표 10. 수명과의 상관; 유효 쌍 B1=46, B2=39, B3=44

피처	B1 Pearson	B1 ρ	B2 ρ	B3 ρ
delta_q_log_var	-0.886	-0.871	-0.709	-0.797
delta_q_min	0.882	0.850	0.661	0.776
delta_q_mean	0.854	0.828	0.697	0.756
chargetime_median	0.745	0.638	-0.809	0.264
qd_change_100_10	0.550	0.613	-0.055	0.032
early_fade_rate	-0.510	-0.586	0.220	-0.132
charge_c1	-0.580	-0.483	0.055	-0.229
tavg_median	-0.499	-0.380	0.172	0.023
tmax_median	-0.412	-0.321	-0.140	-0.049
ir_median	0.336	0.281	-0.344	0.171
switch_soc	0.235	0.185	0.288	0.443
qd_10	0.101	0.100	0.077	0.130
charge_c2	-0.096	0.047	-0.119	0.016

> **Batch 1의 최강 후보는 ΔQ 로그 분산**이다(r=-0.886, ρ=-0.871). 평균·최솟값도 강한 관계를 보인다. Batch 2·3에서 로그 분산은 각각 -0.709, -0.797로 같은 방향이다.

다만 Batch 2에서는 충전 시간의 |ρ|=0.809가 ΔQ 로그 분산보다 크다. 따라서 ΔQ 로그 분산을 모든 배치의 최강 피처라고 표현하지 않는다.

10번째 사이클 Qd 자체의 관계는 세 배치에서 약하다(ρ=0.077–0.130). 초기 용량의 크기보다 곡선 사이의 변화가 후보 신호로 더 뚜렷했다. 충전 시간과 내부 저항 등은 배치별 부호가 달라 일반화 검증이 필요하다.

6.1 피처 간 중복 관계

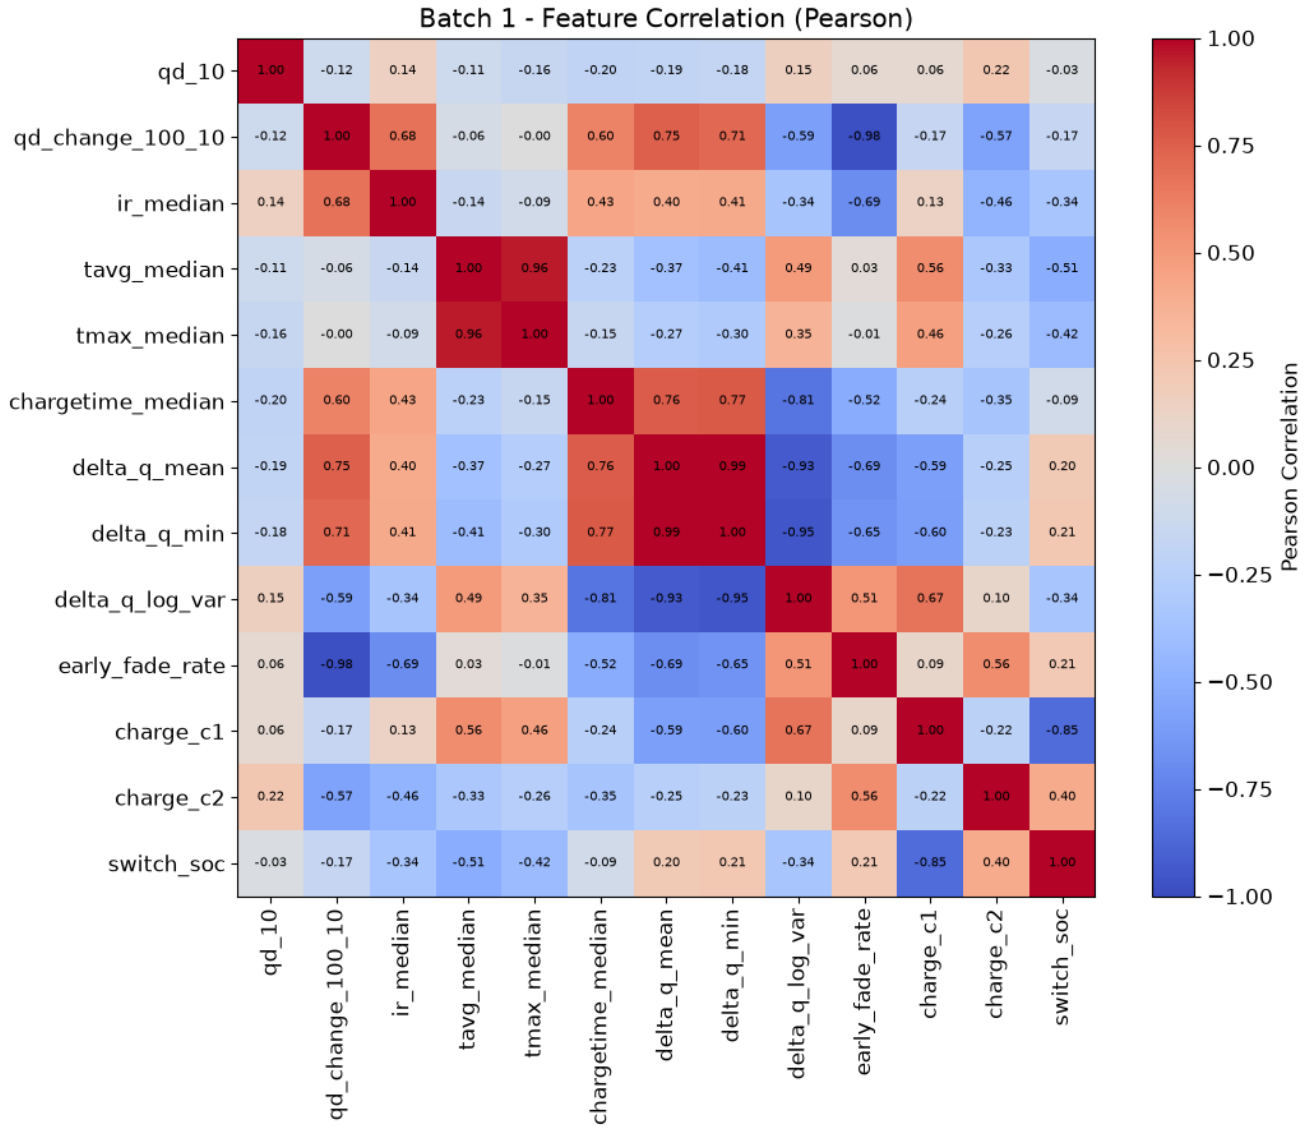


그림 8. Batch 1의 피처 간 Pearson 상관. 셀 46개, 피처 13개. 타깃과 식별자는 행렬에서 제외했다.

표 11. |r| ≥ 0.9인 피처 쌍

피처 1	피처 2	Pearson r	n
delta_q_mean	delta_q_min	0.993	46
qd_change_100_10	early_fade_rate	-0.979	46
tavg_median	tmax_median	0.960	46
delta_q_min	delta_q_log_var	-0.947	46
delta_q_mean	delta_q_log_var	-0.926	46

높은 상관의 주요 묶음은 ΔQ 통계, 초기 용량 변화량·감소율, 평균·최고 온도다. 0.9는 이번 EDA의 점검 기준이며 자동 삭제 임계값으로 확정하지 않았다.

6.2 VIF와 피처 축소 방향

Batch 1의 완전 관측 46셀과 13피처를 사용했다. 상수 또는 유효값 부족으로 제외된 피처는 없었다. 각 피처를 나머지 피처로 선형 설명한 R^2에서 $VIF=1/(1-R^2)$를 계산했다. 중심화·스케일 조정은 진단용이며 모델 전처리에 재사용하지 않는다.

표 12. 현재 후보 피처를 함께 사용했을 때의 VIF

피처	VIF
delta_q_min	154.64
delta_q_mean	117.71
qd_change_100_10	49.12
early_fade_rate	42.68
tavg_median	42.24
delta_q_log_var	38.06
tmax_median	30.83
charge_c1	16.22
switch_soc	12.53
chargetime_median	7.58
ir_median	3.76
charge_c2	3.25
qd_10	1.47

ΔQ 최솟값·평균의 VIF는 154.64·117.71이며 초기 용량 변화량, 감소율, 온도 피처의 VIF도 높다. 함께 사용하는 선형 모델에서 계수 추정과 해석이 불안정해질 가능성이 크다.

> **높은 VIF는 피처의 무용성을 뜻하지 않는다.** ΔQ 로그 분산은 타깃 관계가 강하지만 다른 ΔQ 통계와 함께 넣으면 VIF가 38.06이다. 관련 피처군에서 대표를 선택하거나 규제를 사용하고, 변경 후 내부 검증으로 성능과 안정성을 확인한다.

기준 모델 후보에는 ΔQ 로그 분산 하나를 사용하는 방안을 검토한다. 확장 후보에서는 Qd 변화량과 감소율 중 하나, 평균·최고 온도 중 하나를 우선 검토한다. 최종 선택을 이 표만으로 확정하지 않는다.

7. 배치 비교와 회귀 태스크

표 13. 세 배치의 핵심 차이

관점	Batch 1	Batch 2	Batch 3
수명 중심	중앙값 858.5	중앙값 472.0	중앙값 1,005.5
단수명 / 장수명	0.0% / 21.7%	71.8% / 7.7%	0.0% / 52.3%
ΔQ 로그 분산 ρ	-0.871	-0.709	-0.797
충전 시간 ρ	0.638	-0.809	0.264
주요 한계	46셀 소표본	수명 결측 8셀·설정 파싱 실패 8셀	수명 결측 2셀·충전 구성 차이

선택한 회귀 태스크

회귀를 선택한다. 입력 X는 초기 100사이클 이내의 셀별 요약 피처이고, 타깃 y는 제공된 총 `cycle_life`다. EOL80% 까지의 총 사이클 수를 예측하는 과제이며, 관측 시점부터 남은 잔여수명(RUL)과 구분한다.

ΔQ100−10이 현재 가장 뚜렷한 후보 신호이고, 연속적인 수명 차이를 예측하려는 목적과 맞는다. 과제의 초기 5사이클 분류를 선택하면 관측 범위가 달라 현재 피처를 그대로 사용할 수 없다. DAY1의 >1,000/<500 그룹은 EDA 비교 기준이다.

$$\text{초기 100사이클 X} \rightarrow \log_{10}(\text{cycle_life}) \rightarrow 10^{\text{예측값}} \text{ 사이클}$$

로그 타깃은 **DAY2 학습 전략**이다. 이번 보고서에서 로그 타깃 모델을 학습하거나 역변환 성능을 계산하지 않았다. MAPE와 RMSE는 역변환 후 원래 사이클 단위에서 평가할 계획이다.

> **표본 범위:** 회귀 학습 전 제공된 cycle_life가 실제 EOL 관측인지, 실험 종료까지의 기록 길이인지 대조한다. Batch 1의 일부 종료 곡선과 라벨 관계는 아직 확인되지 않았다. 데이터에 없는 타깃을 임의로 보완하지 않는다.

7.1 입력 피처의 정의와 범위

표 14. 현재 추출한 후보 피처 사전

이름	정의	단위	관측	선택·주의
qd_10	cycle 10의 Qd	Ah	10	초기 용량 기준; 상관 약함
qd_change_100_10	Qd100−Qd10	Ah	10·100	감소율과 중복(-0.979)
ir_median	IR 중앙값	원자료 저항 단위[1]	10–100	배치별 상관 부호 차이
tavg_median	Tavg 중앙값	°C	10–100	Tmax와 중복(0.960)
tmax_median	Tmax 중앙값	°C	10–100	Tavg 대표 사용 시 보류
chargetime_median	충전 시간 중앙값	원자료 시간 단위[1]	10–100	배치별 관계 반전
delta_q_mean	전압별 ΔQ 평균	Ah	10·100	최솟값과 중복(0.993)
delta_q_min	전압별 ΔQ 최솟값	Ah	10·100	다른 ΔQ 통계와 중복
delta_q_log_var	log10 Var(ΔQ), ddof=0	Ah^2의 수치에 log10	10·100	핵심 후보; 분산0은NaN
early_fade_rate	−1000×Theil–Sen 기울기	mAh/cycle	10–100	Qd 변화량과 중복
charge_c1 / c2	1·2단계 충전 설정	C	프로토콜	특수 표기 8셀 파싱 실패
switch_soc	전류 전환 시점 설정	%	프로토콜	다른 충전 설정과 연관

[1] IR·chargetime의 물리 단위는 현재 분석에서 확정하지 않아 원자료 단위로 유지했다. DAY2 전 데이터 사전과 대조한다. 온도·전압·용량 등은 수업 데이터 설명 및 그래프 표기를 따른다.

누락과 누수 처리

동일 셀은 (batch, cell_id)로 연결하되 식별자 자체는 입력에서 제외한다. cycle_life, 장·단수명 그룹, 전체 생애 길이, 종료 용량, 후기 knee를 입력으로 넣지 않는다. 결측 타깃은 대치하지 않고, 입력 결측 처리 규칙은 학습 폴드에서 정한다.

최대 관측 시점은 100사이클로 고정한다. 중앙값 계산은 유한한 값만 사용했으므로 DAY2에는 셀별 유효 관측 수와 누락 위치도 확인한다. 여러 사이클 행을 독립 샘플로 분할하지 않는다.

7.2 EDA에서 모델 설계로

표 15. 근거 → 선택 → 모델 → 검증 → 한계

확인한 EDA 결과	피처·처리 선택	후보 모델과 이유	내부 검증 계획	한계
B1 ΔQ 로그 분산 ρ=-0.871	로그 분산 단일 기준 피처	단변량 선형 회귀: 핵심 신호의 기준 성능	같은 그룹 CV에서 기준 MAPE/RMSE	상관이 성능을 보장하지 않음
ΔQ 평균/최솟값 r=0.993; 높은 VIF	대표 ΔQ 통계 선택·중복 후보 축소	Ridge / Elastic Net: 규제로 계수 안정화	피처군 추가 전후 CV·폴드 변동 비교	표본 46셀로 선택 불안정 가능
Qd 변화/감소율 r=-0.979; Tavg/Tmax r=0.960	각 묶음에서 대표 하나를 우선 검토	소수 피처의 규제 선형 모델	같은 분할에서 후보 조합 비교	원자료 단위·측정 이상 확인 필요
충전 시간 관계 0.638→-0.809	충전 시간·설정은 보조 후보	기준 모델 대비 추가 효과 검토	Batch 1 내부에서만 채택 판단	배치 조건이 달라 관계 반전 가능
수명 분포·프로토콜 구성이 다름	같은 셀/프로토콜을 그룹으로 관리	작은 모델부터 비교	B1 그룹 hold-out/CV, 고정 후 B2 평가	B2·3 타깃 EDA를 이미 관찰함

소표본에 맞춘 비교

Batch 1은 셀 46개이므로 다수의 피처·복잡한 모델을 동시에 탐색하면 내부 결과에 맞출 위험이 커진다. 기본 단일 피처 모델과 제한된 확장 피처군을 먼저 비교한다.

딥러닝은 이번 후보의 우선순위에서 제외한다. 셀별 요약 입력과 작은 표본 규모에서는 표현학습의 이점을 검증하기 어렵고, 모델의 해석과 검증 안정성이 중요하기 때문이다. 전통적 ML이 항상 우수하다는 의미는 아니다.

> 규제 강도·피처 조합·최종 모델의 우열은 아직 미정이다. DAY1의 상관·VIF 결과는 후보 설계의 근거이며, 실제 점수와 선택 결과는 DAY2에 기록한다.

8. 후보 모델과 검증 계획

표 16. 학습 전 후보 모델

후보	역할	검토 근거
로그 분산 단독 선형 회귀	기준 모델	가장 강한 초기 신호 한 개의 예측력 확인
Ridge	규제 후보	다중공선성 하에서 계수 크기를 제약
Elastic Net	규제·선택 후보	L1/L2 규제로 피처 선택과 계수 안정성을 검토

분할과 선택 순서

1. 타깃 정의·동일 물리 셀 연결·제외 규칙을 먼저 대조한다. 실제 파일 날짜가 다른 논문의 인덱스를 그대로 적용하지 않는다.
2. Batch 1을 셀 단위로 구성하고 충전 프로토콜 그룹을 고려해 내부 학습과 hold-out을 나눈다. 예시 계획은 프로토콜 약 20% hold-out, 나머지 그룹 기반 3-fold CV다. 실제 그룹 수와 분할 타깃 분포를 기록한다.
3. 대치·표준화·피처 선택은 각 CV 학습 폴드에서만 fit한다. 동일 분할로 후보를 비교하고 CV 평균 MAPE와 폴드 변동을 확인한다.
4. 선택한 설정의 hold-out 성능을 확인하고 설정을 고정한다. 사전 선택된 모델을 Batch 1 전체로 재학습한 뒤 Batch 2를 최종 평가한다.

무작위 분할·모델 단계가 있으면 seed/random_state=42를 사용한다. Batch 3는 DAY1 EDA에 포함했으며, 선택적 DAY2 추가 성능 검증은 이번에 생략한다.

평가 지표

주 지표 MAPE(%)는 상대 오차를, **보조 지표 RMSE(사이클)**는 큰 절대 오차를 확인한다. 로그 예측은 사이클 단위로 역변환한다. 과제 양식의 Train은 단순 훈련 적합 점수가 아니라 Batch 1 내부 CV 결과로 보고한다.

> **정직한 평가 범위:** 과제에 따라 Batch 2·3의 타깃 기반 EDA를 이미 보았다. 완전히 미관찰인 test와 동등하다고 주장하지 않는다. 이후 피처·튜닝은 Batch 1 내부에서 수행하고 Batch 2 성능을 보고 반복 수정하지 않는다.

부록 A1. 프로토콜 원본 요약

부록 표 A1. Batch 1 전체 프로토콜 요약

프로토콜	전체 n	수명 n	평균 수명	중앙 수명	평균 감소율
4C(80%)-4C	2	2	1,226.5	1,226.5	0.001
3.6C(80%)-3.6C	3	3	1,182.0	1,179.0	0.009
4.4C(80%)-4.4C	1	1	1,074.0	1,074.0	0.005
8C(15%)-3.6C	2	2	1,008.5	1,008.5	0.016
5.4C(40%)-3.6C	2	2	966.5	966.5	0.003
6C(30%)-3.6C	2	2	952.5	952.5	0.018
6C(40%)-3C	2	2	935.5	935.5	0.012
5.4C(50%)-3.6C	2	2	899.5	899.5	0.007
6C(50%)-3C	2	2	888.5	888.5	0.015
5.4C(60%)-3.6C	2	2	859.5	859.5	-0.003
6C(40%)-3.6C	2	2	856.0	856.0	0.023
5.4C(50%)-3C	2	2	847.0	847.0	0.004
5.4C(60%)-3C	2	2	799.5	799.5	-0.010
6C(50%)-3.6C	2	2	792.5	792.5	0.033
4.8C(80%)-4.8C	2	2	753.0	753.0	0.024
6C(60%)-3C	2	2	744.0	744.0	0.028
5.4C(70%)-3C	2	2	739.5	739.5	0.043
7C(30%)-3.6C	2	2	722.5	722.5	0.011
8C(25%)-3.6C	2	2	676.5	676.5	0.020
7C(40%)-3C	2	2	676.0	676.0	0.021
7C(40%)-3.6C	2	2	621.0	621.0	0.018
8C(35%)-3.6C	2	2	607.5	607.5	0.034
5.4C(80%)-5.4C	2	2	546.5	546.5	0.130

수명 단위: 사이클. 감소율 단위: mAh/cycle. 평균 감소율은 수명 결측과 무관하게 계산 가능하다. [NS]는 원본 -newstructure 표기. 프로토콜별 표준편차·신뢰구간은 산출하지 않았다.

부록 A2. 프로토콜 원본 요약

부록 표 A2. Batch 2 전체 프로토콜 요약

프로토콜	전체 n	수명 n	평균 수명	중앙 수명	평균 감소율
5.6C(26%)-4.5C [NS]	3	3	991.3	997.0	0.039
5.2C(58%)-4C [NS]	3	3	961.7	904.0	0.030
4.8C(80%)-4.8C [NS]	3	3	871.7	809.0	0.022
4.8C(80%)-4.8C	5	5	483.6	492.0	-0.032
4.65C(44%)-5C	2	2	482.5	482.5	-0.059
5.2C(58%)-4C	4	4	477.8	483.0	-0.052
5.2C(50%)-4.25C	5	5	454.0	449.0	-0.076
4.65C(69%)-6C	2	2	452.0	452.0	0.036
5.6C(26%)-4.5C	6	6	448.5	446.0	-0.001
3.6C(30%)-6C	2	2	421.0	421.0	0.141
6C(60%)-3C	2	2	400.0	400.0	-0.027
3.6C(9%)-5C	2	2	394.5	394.5	-0.079
3.6C(80%)-3.6C(SLOWCYCLE	1	0	—	—	0.005
3.6C(9%)-5C(SLOWCYCLE	1	0	—	—	0.068
4.8C(80%)-4.8C(SLOWCYCLE	1	0	—	—	0.048
5.2C(58%)-4C(SLOWCYCLE	1	0	—	—	0.011
VarCharge-2C-100cycles	1	0	—	—	0.027
VarCharge-4C-100cycles	1	0	—	—	0.085
VarCharge-6C-100cycles	1	0	—	—	0.413
VarCharge-8C-100cycles	1	0	—	—	0.781

수명 단위: 사이클. 감소율 단위: mAh/cycle. 평균 감소율은 수명 결측과 무관하게 계산 가능하다. [NS]는 원본 -newstructure 표기. 프로토콜별 표준편차·신뢰구간은 산출하지 않았다.

부록 A3. 프로토콜 원본 요약

부록 표 A3. Batch 3 전체 프로토콜 요약

프로토콜	전체 n	수명 n	평균 수명	중앙 수명	평균 감소율
4.8C(80%)-4.8C [NS]	8	6	1,564.2	1,640.0	0.013
5C(67%)-4C [NS]	7	7	1,105.7	1,009.0	0.013
5.3C(54%)-4C [NS]	8	8	1,074.4	1,051.0	0.016
5.6C(19%)-4.6C [NS]	8	8	1,001.4	1,038.0	0.023
5.6C(36%)-4.3C [NS]	8	8	930.9	890.5	0.020
5.9C(15%)-4.6C [NS]	2	2	867.0	867.0	0.015
5.9C(60%)-3.1C [NS]	2	2	866.5	866.5	0.023
3.7C(31%)-5.9C [NS]	3	3	660.0	667.0	0.191

수명 단위: 사이클. 감소율 단위: mAh/cycle. 평균 감소율은 수명 결측과 무관하게 계산 가능하다. [NS]는 원본 -newstructure 표기. 프로토콜별 표준편차·신뢰구간은 산출하지 않았다.

설정 추출 실패 원본 표기

부록 표 A4. 파싱 실패 8셀

Batch 2 cell_id	원본 프로토콜
22	VarCharge-2C-100cycles
23	VarCharge-4C-100cycles
35	VarCharge-6C-100cycles
36	VarCharge-8C-100cycles
37	3.6C(80%)-3.6C(SLOWCYCLE
38	4.8C(80%)-4.8C(SLOWCYCLE
39	3.6C(9%)-5C(SLOWCYCLE
40	5.2C(58%)-4C(SLOWCYCLE

모두 수명 결측 셀이다. 표기 차이로 현재 파싱 규칙에 맞지 않았으며 데이터 오류로 판정하지 않았다.